

# 금융투자에서의 기계학습 기술 적용 동향

---

2017년 10월 31일

유성준

[sjyoo@sejong.ac.kr](mailto:sjyoo@sejong.ac.kr)

<http://abrc.or.kr/>

세종대학교 인공지능-빅데이터연구센터 센터장

세종대학교 컴퓨터공학과 교수

# 목차

**I** 기계학습 이론 리뷰

**II** 금융투자 이론 간단 리뷰

**III** AI/ML 기술을 포트폴리오 및 매매시점  
예측에 적용한 사례

# 이 자료의 범위

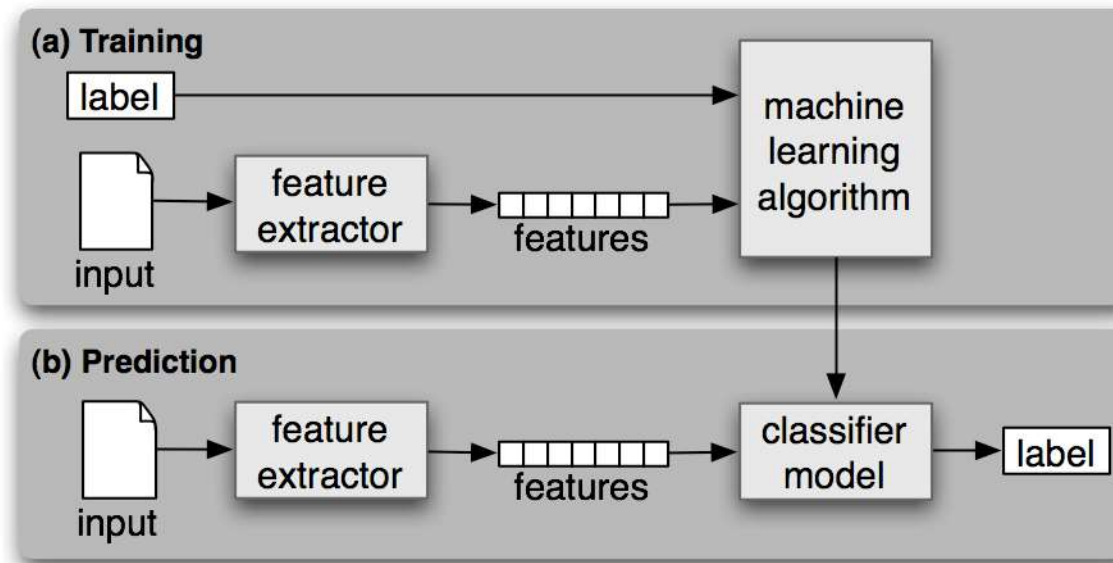
- 금융 투자에 AI/기계학습 기술을 적용한 기사 및 논문 몇 개를 요약하여 정리한 자료입니다.
- 우리 연구실 실험결과 자료도 일부 포함하였습니다.



# I. 기계학습 이론 리뷰

# 기계학습 이론 다시 보기 - 지도학습

- 지도학습:
    - 훈련 데이터를 보여주면서 해당 데이터가 어디에 속하는지 지도하여 학습시킴
    - Support Vector Machine(SVM), Naïve Bayes Classification, Hidden Markov Model, Regression, Neural Network 외 다수
- ([https://en.wikipedia.org/wiki/Supervised\\_learning](https://en.wikipedia.org/wiki/Supervised_learning) 참고)



그림출처: <http://www.nltk.org/book/ch06.html>

## Feature의 정의 및 중요성

- 기계학습은 보통 중간 단계인 특징 추출(feature extraction)을 거쳐 data→feature→knowledge 의 단계로 학습하는 것이 보통입니다.
- 예를 들어 사진 속에서 사물을 인식하기 위해 픽셀 값에서 먼저 특징적인 선이나 특징적인 색 분포 등을 먼저 추출한 후 이를 기반으로 '이건 사과다' '이건 바나나다'라는 판단을 내리는 것이죠. 이러한 중간 표현단계를 특징 지도(feature map)이라고 하는데요, 기계학습의 성능은 **얼만큼 좋은 특징들을 뽑아내느냐**에 따라 그 성능이 매우 크게 좌지우지 됩니다. (이는 이미지 처리뿐만 아니라 음성 인식, 자연어 분석 등 대부분의 기계학습에 적용되는 이야기입니다.)

- 출처: [http://t-robotics.blogspot.kr/2015/05/deep-learning.html#.WILUn\\_mLSUk](http://t-robotics.blogspot.kr/2015/05/deep-learning.html#.WILUn_mLSUk)



## II. 금융 이론 리뷰

# Motivation

- 투자 모델의 주요 목표
  - 리스크 최소화 및 수익률 최대화
- 포트폴리오
  - 이익을 최대화하고 위험을 최소화 하는 목적으로 최적의 비율로 나뉜 투자자산의 집합
- Mean Variance Model
  - Markowitz, 1952.
  - This model can be used by investors to achieve desired returns from portfolio with minimum possible risk.
  - In fact, this theory has wide spread acceptance and has been used as a practical tool for portfolio optimization.

Harry  
Markowitz  
American economist



Harry Max Markowitz is an American economist, and a recipient of the 1989 John von Neumann Theory Prize and the 1990 Nobel Memorial Prize in Economic Sciences. [Wikipedia](#)

**Born:** August 24, 1927 (age 90), Chicago, Illinois, United States

**Nationality:** American

**Education:** University of Chicago

**School or tradition:** Chicago School of Economics



## 기본지식정리 - 기대 수익률 및 분산

Q. 아래 주식A와 주식B를 몇 대 몇으로 혼합하면 좋을까?

경제상황	확률	주식A	주식B
호황	0.3	8%	4%
보통	0.4	6%	5%
불황	0.3	5%	6%

기대수익률 구하기

$$E(R_A) = 0.3 \times 8\% + 0.4 \times 6\% + 0.3 \times 5\% = 6.3\%$$

표준편차 구하기

$$\sigma_A^2 = 0.3 \times (8\% - 6.3\%)^2 + 0.4 \times (6\% - 6.3\%)^2 + 0.3 \times (5\% - 6.3\%)^2 = 0.11874$$

$$\sigma_A = 0.108968$$

# 기본지식정리 - 포트폴리오의 기대수익률 및 volatility

For a two asset portfolio:

- Portfolio return:  $E(R_p) = w_A E(R_A) + w_B E(R_B) = w_A E(R_A) + (1 - w_A) E(R_B)$ .
- Portfolio variance:  $\sigma_p^2 = w_A^2 \sigma_A^2 + w_B^2 \sigma_B^2 + 2w_A w_B \sigma_A \sigma_B \rho_{AB}$

<출처: [https://en.wikipedia.org/wiki/Modern\\_portfolio\\_theory](https://en.wikipedia.org/wiki/Modern_portfolio_theory)>

주식A의 기대수익률

주식 A에 50%, 주식 B에 50% 투자한 포트폴리오 구성

기대수익률 구하기

주식B의 기대수익률

$$E(R_p) = 50\% \times 6.3\% + 50\% \times 5\% = 5.65\%$$

표준편차(return volatility) 구하기

$$\sigma_p^2 = 0.5^2 \times \sigma_A^2 + 0.5^2 \times \sigma_B^2 + 2 \times 0.5^2 \times \sigma_A \times \sigma_B \times (-0.978) = 0.0000005273$$

$$\sigma_p = 0.002296$$

가정치

## Motivation

15.401

### What Is A Portfolio and Why Is It Useful?

- A **portfolio** is simply a specific combination of securities, usually defined by **portfolio weights** that sum to 1:

$$\omega = \{ \omega_1, \omega_2, \dots, \omega_n \}$$

$$\omega_i = \frac{N_i P_i}{N_1 P_1 + \dots + N_n P_n}$$

$$1 = \omega_1 + \omega_2 + \dots + \omega_n$$

- Portfolio weights can sum to 0 (dollar-neutral portfolios), and weights can be positive (long positions) or negative (short positions).
- Assumption: Portfolio weights summarize all relevant information.

출처: Andrew W. Lo, Finance Theory, Lecture Note 13-14, MIT Sloan School, 2007-2008

## Mean-Variance Analysis

15.401

**Example:** From 1946 – 2001, Motorola had an average monthly return of 1.75% and a std dev of 9.73%. GM had an average return of 1.08% and a std dev of 6.23%. Their correlation is 0.37. How would a portfolio of the two stocks perform?

$$E[R_p] = \omega_{GM} 1.08 + \omega_{MOT} 1.75$$

$$Var[R_p] = \omega_{GM}^2 6.23^2 + \omega_{MOT}^2 9.73^2 + 2\omega_{GM}\omega_{MOT} (0.37 \times 6.23 \times 9.73)$$

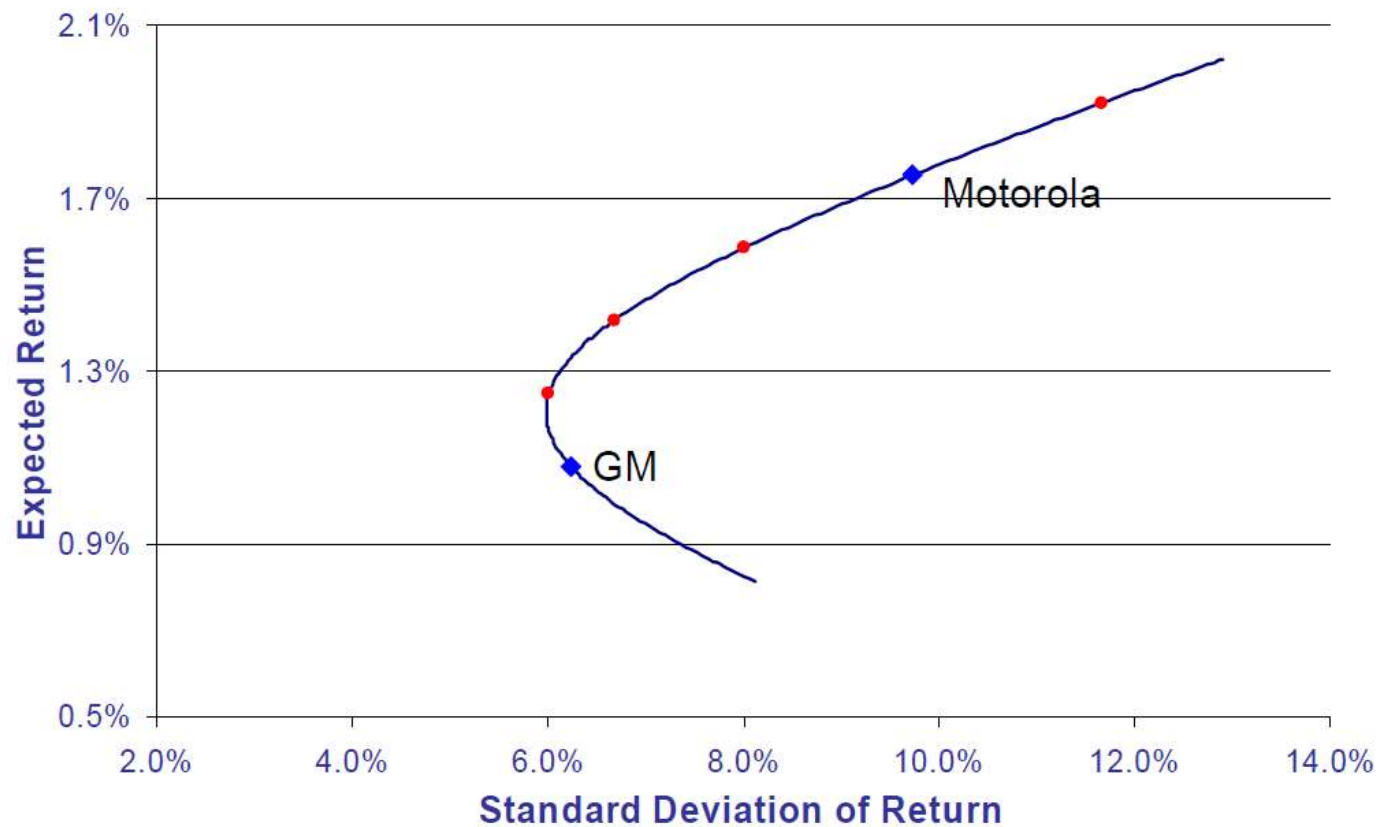
$\omega_{Mot}$	$\omega_{GM}$	$E[R_P]$	$var(R_P)$	$stdev(R_P)$
0	1	1.08	38.8	6.23
0.25	0.75	1.25	36.2	6.01
0.50	0.50	1.42	44.6	6.68
0.75	0.25	1.58	64.1	8.00
1	0	1.75	94.6	9.73
1.25	-0.25	1.92	136.3	11.67

출처: Andrew W. Lo, Finance Theory, Lecture Note 13-14, MIT Sloan School, 2007-2008

## Mean-Variance Analysis

15.401

Mean/SD Trade-Off for Portfolios of GM and Motorola



출처: Andrew W. Lo, Finance Theory, Lecture Note 13-14, MIT Sloan School, 2007-2008


## 포트폴리오 종목 선정 예 - Style Factors




# Performance of a Model

누적수익률(cumulative return)

$$= ((\text{Current Price of Security}) - (\text{Original Price of Security})) / (\text{Original Price of Security})$$




# Performance of a Model





## Performance of a Model

초기값이 \$500, 일정기간동안(over a period of time)의 **최고값이 \$750**까지 도달 후  
\$400로 하락했다가 다시 \$600로 상승,  
다시 **\$350까지 하락** 후 \$800까지 재상승할 경우  
 $\text{Maximum Drawdown} = (\$350 - \$750) / \$750 = -53.3\%$



# Performance of a Model

Sharpe ratio = (Mean [portfolio return](#) - Risk-free rate)/Standard deviation of portfolio return

$$= \frac{\bar{r}_p - r_f}{\sigma_p}$$

Where:

$\bar{r}_p$  = Expected portfolio return


$r_f$  = Risk free rate

$\sigma_p$  = Portfolio standard deviation

예를 들어 1년동안 [코스피](#)가 20% 오르고 내 포트폴리오가 30% 올랐는데, 내 포트폴리오의 월간 수익률에서 코스피의 월간 수익률을 뺀 값의 표준편차가 5%라면, 사후적 샤프 비율은  $(0.3-0.2)/(0.05*12^{(1/2)}) = \text{약 } 0.57$ 이 된다.

높은 샤프지수를 기록하는 투자일수록 더 적은 [위험](#)으로 더 높은 수익률을 내는 것이라고 볼 수 있다. 그러므로 샤프지수가 높은 펀드 혹은 포트폴리오가 더 좋은 포트폴리오라고 볼 수 있다. 기본적으로 샤프지수가 0 이상이어야 투자의 고려대상이 될 수 있고 1 이상이면 상당히 괜찮은 투자라고 볼 수 있다.

출처: <https://namu.wiki/w/%EC%83%A4%ED%94%84%20%EB%B9%84%EC%9C%A8>



# **III. AI/ML 기술을 이용한 포트폴리오 및 매매시점 예측에 적용한 사례**

# How AI Is Transforming Investment Management

- <https://hk.asiatatler.com/life/artificial-intelligence-investment-management>
- May 30, 2017
- AI hedge funds generated impressive average returns during the six years to 2016, according to research company Eurekahedge's AI/Machine Learning Hedge Fund Index, which tracks 23 such funds.
- 가장 잘 알려진 것 중에는 8 년 전에 설립 된 Cerebellum Capital
  - 클라우드 컴퓨팅 및 기계 학습의 발전과 사용 가능한 데이터의 양이 증가
  - 이 회사는 최근에 처음으로 진정한 자동화 기계 학습 펀드를 시작
  - 현재는 창립자 및 지인들이 돈을 주로 투자하고 있지만 기관 투자자와 협상 중

# How AI Is Transforming Investment Management

- The company's CEO David Andre says the biggest problem in developing the software has been setting too much store by particular pieces of data, an issue known as **overfitting**. "Most of the development has come down to one core problem: **how can you tell when a model has been overfit or not?**" he says. "You find things that do terrifically in the past but not so well in the future."

# How AI Is Transforming Investment Management

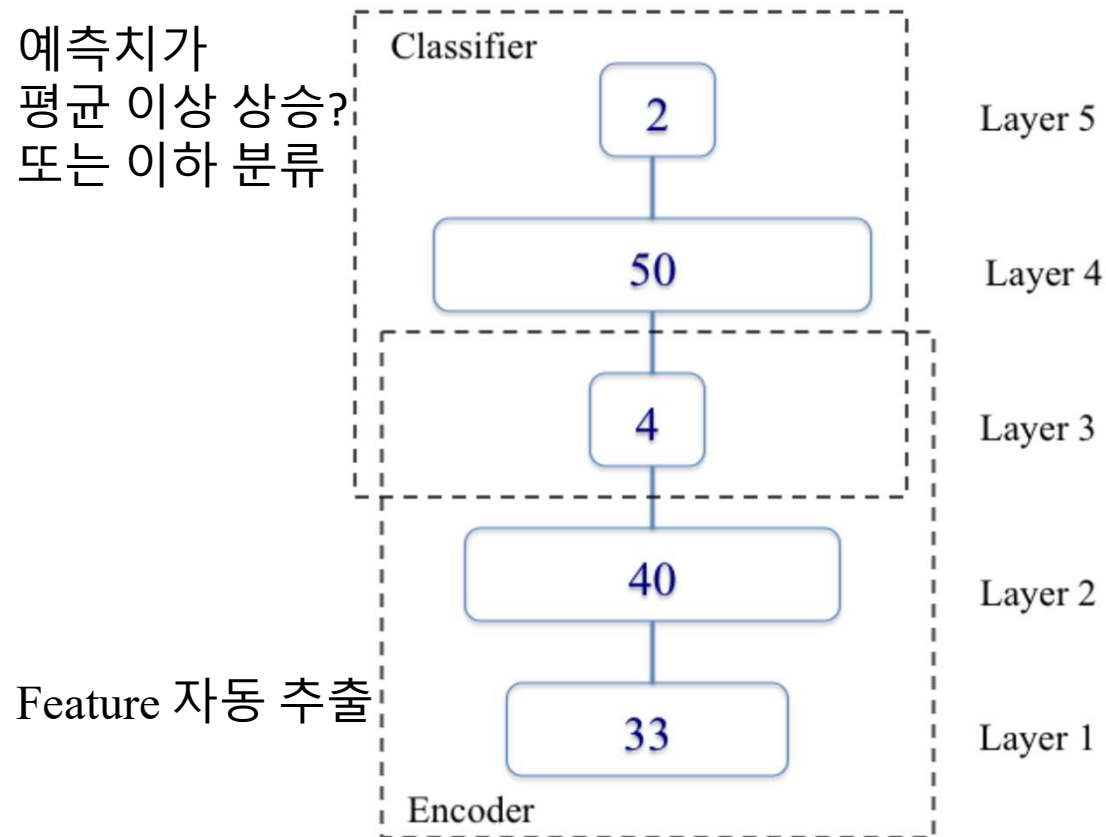
- Bridgewater Associates, BlackRock, Point72 Asset Management, UBS 및 Morgan Stanley와 같은 다양한 금융기관은 AI라는 물속에 발을 담그기 시작
- 하지만 투자 전략을 만들기보다는 아이디어를 창출하는 방법으로 AI를 사용하고있음
- PricewaterhouseCoopers에 따르면 금융 회사의 26 %가 의사 결정에 이 전략을 사용중

# Will AI-Powered Hedge Funds Outsmart the Market?

- 그러나 모든 사람이 금융에서 AI 혁명이 임박했다는 것을 확신하지는 않음
- 영국의 무역 회사 인 Winton Capital Management의 억만 장자 창립자이자 CEO 인 David Harding은 일반적으로 기계 학습 및 AI에 대한 과대 선전에 회의적
- "내가 조금씩 훑어보고 Winton을 살펴 본다면, 지난 30 년 동안 우리가 해왔 던 것과 큰 차이가 없다고 말할 수 있음
- Harding은 또한 신경 네트워크에 대한 관심이 비슷한 1990 년대 초반에 많은 신 생 기업을 탄생 시켰음을 기억
- 그는 "사람들은 '전에는 모든 것을 날려 버릴 놀라운 새로운 컴퓨팅 기술이있다'며 '유전 알고리즘에 대한 유행도 있었다'고 회상

<출처: <https://www.technologyreview.com/s/600695/will-ai-powered-hedge-funds-outsmart-the-market/>, by [Will Knight](#)  
February 4, 2016, MIT Technology>

# Applying Deep Learning to Enhance Momentum Trading Strategies in Stocks



출처: Lawrence Takeuchi and Yu-Ying (Albert) Lee, “Applying Deep Learning to Enhance Momentum Trading Strategies in Stocks” Stanford Univ.



# Applying Deep Learning to Enhance Momentum Trading Strategies in Stocks




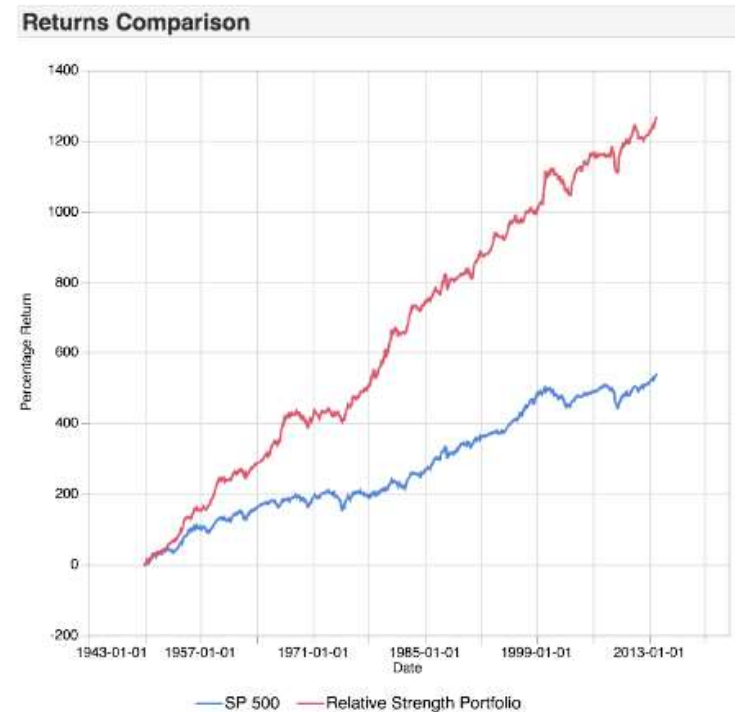
Figure 4. Log Growth in Cumulative Wealth

출처: Lawrence Takeuchi and Yu-Ying (Albert) Lee, “Applying Deep Learning to Enhance Momentum Trading Strategies in Stocks” Stanford Univ.

# Quantitative Tactical Asset Allocation Using Ensemble Machine Learning Methods

- 각 섹터별로 지난달의 월간 수익률을 구하고 그 중 최고의 수익률을 거둔 섹터를 buy
- 지금이 1월이라고 하면 지난 12월의 수익률을 구함

$$monthlyReturn = 100 * \left[ \left( \frac{price(t-1)}{price(t-2)} \right) - 1 \right]$$



출처: Kemal Oflus, “Quantitative Tactical Asset Allocation Using Ensemble Machine Learning Methods”  
<http://ssrn.com/abstract=2438522>

# Quantitative Tactical Asset Allocation Using Ensemble Machine Learning Methods

## ETF로 투자할 경우의 시뮬레이션 결과

Table 4: Industry Descriptions

ETF	Industry/Index
XLY(4)	Consumer Discretionary
XLP(4)	Consumer Staples
XLE	Energy
XLF	Financials
XLV	Health Care
XLI	Industrials
XLB	Materials
XLK	Technology
XLU	Utilities
TLT(5)	20+ Year Treasury Bond
IYR	US Real Estate
EEM	MSCI Emerging Markets
EFA	MSCI EAFE



출처: Kemal Oflus, "Quantitative Tactical Asset Allocation Using Ensemble Machine Learning Methods" <http://ssrn.com/abstract=2438522>

# Quantitative Tactical Asset Allocation Using Ensemble Machine Learning Methods


- 모멘텀 Filter를 사용하는 경우
- Cumulative Return이 Moving Average 위에 있을 때에만 해당 섹터 buy
- 그렇지 않은 경우는 no position
- Improved CAGR(compound Annual Growth Rate) by 150 basis points by increasing from 9.04% to 10.58%.



출처: Kemal Oflus, “Quantitative Tactical Asset Allocation Using Ensemble Machine Learning Methods”  
<http://ssrn.com/abstract=2438522>

# Quantitative Tactical Asset Allocation Using Ensemble Machine Learning Methods

- 앙상블 모델을 이용하여 주가 예측 후 섹터 선정(논문에서는 더 이상 상세 내용 없음)
- The ensemble model consists of Gradient boosted decision trees and neural network models



출처: Kemal Oflus, “Quantitative Tactical Asset Allocation Using Ensemble Machine Learning Methods”  
<http://ssrn.com/abstract=2438522>


## ANN + Wavelet 기반 상승/하락 예측

- 아래와 같이 10가지 기술적 지표를 사용

특징(Features)	설명
DPt-1	t-1과 t-2의 가격 변화율
DPt-2	t-2과 t-3의 가격 변화율
DVt-1	t-1과 t-2의 거래량 변화율
DVt-2	t-2과 t-3의 거래량 변화율
Mat-1(5)	t-1의 5일 이동평균값
Mat-1(10)	t-1의 10일 이동평균값
Mat-1(30)	t-1의 30일 이동평균값
MPPt-1(30)	t-1의 30일 이동평균값의 위치
MPPt-1(120)	t-1의 120일 이동평균값의 위치
PPOt-1	t-1의 가격 오실레이터(Oscillator)

## 주가 트렌드 예측 모델 – 트레이딩

- 특징들의 조합을 ANN모델에 적용
- 거래횟수가 많이 발생하는 문제점이 존재
  - 아래 예제에서는 84회 거래횟수가 발생




## 디노이징(De-noising)

- 거래 횟수를 줄이기 위해 디노이징(De-noising) 기법인 웨이블릿 변환(Wavelet Transform)을 사용
- 웨이블릿 변환(Wavelet Transform)
  - 웨이블릿 신호 함수를 사용해 시계열 데이터를 천이, 확대, 축소의 스케일(Scale)을 통해 임의의 파형으로 표현하는 것임
- 웨이블릿(Wavelet)
  - 특수한 파(Wave) 형태를 갖는 함수
  - 하나의 대역 통과 필터
- 웨이블릿 변환 과정
  - 원본 신호의 분해(Decomposition)
  - 웨이블릿 계수 이외의 계수 값에 0을 부여
  - 웨이블릿 계수 재결합



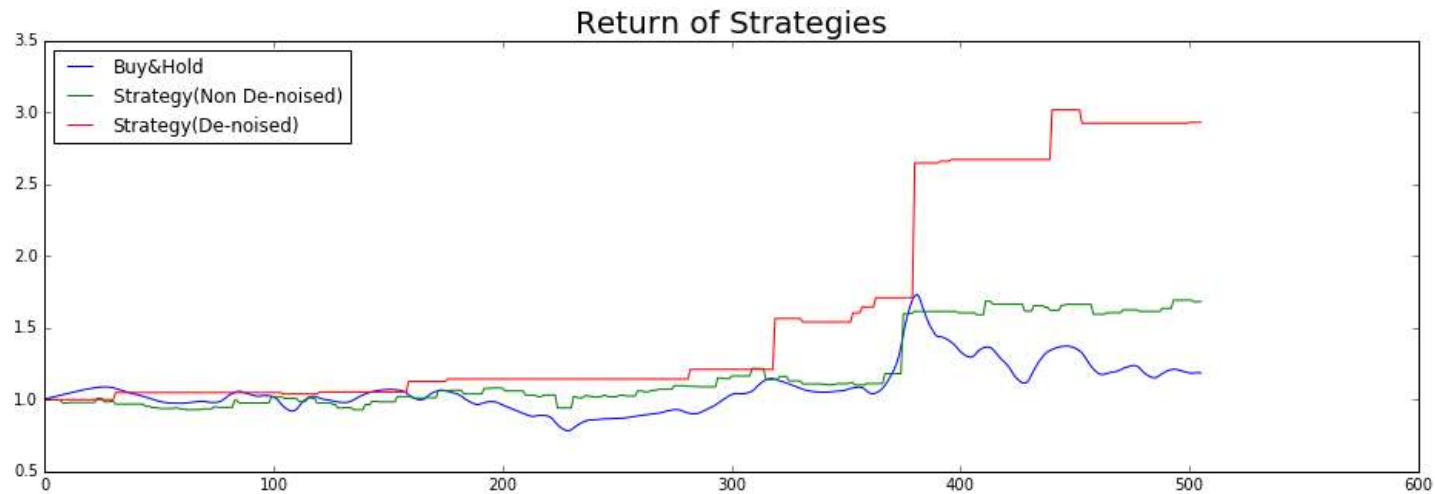
## 실험 결과

- 전략(De-noised)
  - 거래 횟수: 17
  - 누적 수익률: 193.07%
  - Buy&Hold 전략 수익률: 17.3%
- 매수, 매도 시점 표시



# 실험 결과

## ■ 누적 수익률 비교



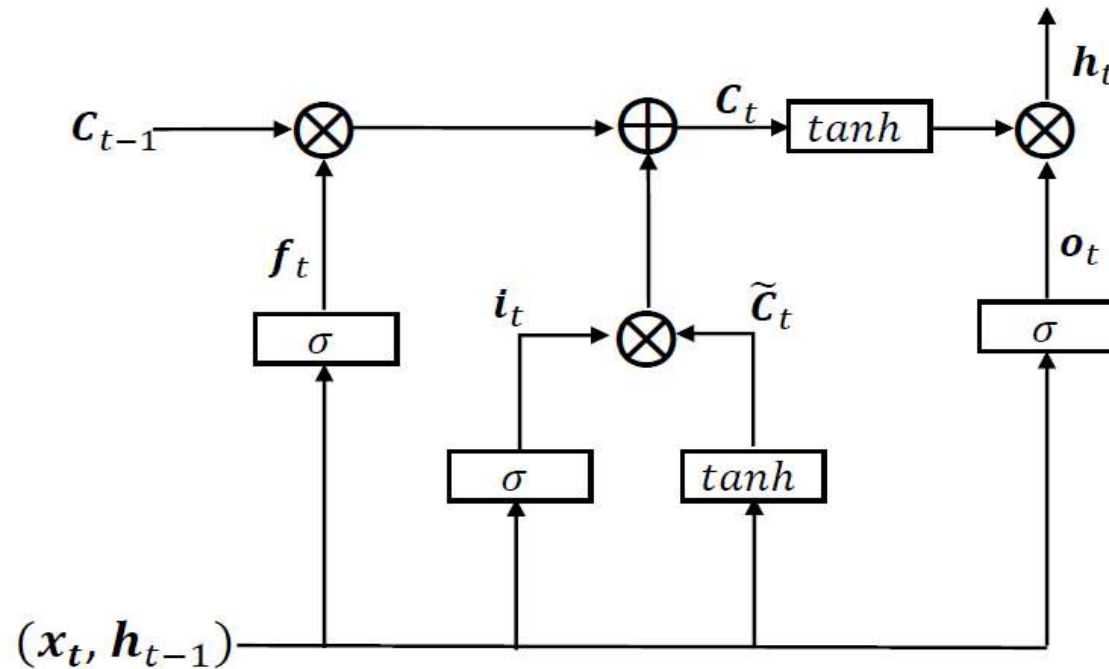
광명전기	Buy&Hold	전략(Non De-noised)	전략(De-noised)
거래 횟수	1	104	17
누적 수익률	17.3%	68.29%	193.07%

# 주가 움직임 예측 기술 동향

제목	데이터 시장 (Stock Market)	기법 (Techniques)	입력 변수 (Input Variable)	성능 (Performance)	디노이징 (De-noising)	트레이딩 (Trading)
J. Patel et al(2015)	Reliance Industries Infosys Ltd CNX Nifty BSE Sensex	ANN SVM Random Forest Naïve Bayes	10 technical indicators	예측 정확도: 89%	X	X
R. Dash et al(2016)	BSE Sensex S&P 500	CEFLANN	6 technical indicators	수익률 BSE: 47.2% S&P: 24.28%	X	O
L.D. Persio and O. Honchar(2016)	S&P 500 FOREX EUR/USD	Wavelet CNN	종가(Close)	MSE: 0.2491 Accuracy: 54%	O	X
M. Qiu, Y. Song(2016)	Nikkei 225 index	GA+ANN	12 technical indicators	예측 정확도 81.27%	X	X
M. Qiu, Y. Song, F. Akagi(2016)	Nikkei 225 index	Genetic Algorithm Simulated Annealing ANN	18 input variables	MSE: 0.0043	X	X
M. Roondiwala et al (2017)	NIFTY 50	LSTM	Open, High, Low, Close	RMSE: 0.00859	X	X
P. Sugiartawan et al(2017)	-	Wavelet + LSTM	Close	MSE: 0.11853 훈련시간 단축	O	X

1. J. Patel, S. Shah, P. Thakkar, K. Kotecha(2015), "Predicting stock and stock price index movement using Trend Deterministic Data Preparation and machine learning techniques" *Expert Systems with Applications*, vol. 42(1), pp. 259-268, 2015.
2. R. Dash, P.K. Dash(2016), "A hybrid stock trading framework integrating technical analysis with machine learning techniques" *The Journal of Finance and Data Science*, vol. 2(1), pp.42-57, 2016.
3. L.D. Persio and O. Honchar(2016), "Artificial neural networks approach to the forecast of stock market price movements" *International Journal of Economics and Management Systems*, 1, 158-162, 2016.
4. M. Qiu, Y. Song and F. Akagi(2016), "Application of artificial neural network for the prediction of stock market returns: The case of the Japanese stock market" *Expert Systems with Applications*, vol. 85, pp.1-7, 2016
5. M. Roondiwala, H. Patel, S. Varma(2017), " Predicting Stock Prices Using LSTM", *International Journal of Science and Research (IJSR)*, vol. 6(4), pp. 1754-1756, 2017.
6. P. Sugiartawan, R. Pulungan, A. K. Sari(2017), " Prediction by a hybrid of Wavelet Transform and Long-Short-Term-Memory Neural Network" *International Journal of Advanced Computer Science and Applications(IJACSA)*, vol.8(2), pp.326-332, 2017.
7. M. Qiu, Y. Song(2016), " Predicting the Direction of Stock Market Index Movement Using an Optimized Artificial Neural Network Model", *PLoS ONE*11(5): e0155133, 2016.

## A Deep Efficient Frontier Method for Optimal Investments



<출처: "A Deep Efficient Frontier Method for Optimal Investments," Sang Il Lee, Seong Joon Yoo, Submitted to and In Revision on Journal of Expert Systems with Applications>

We use data for January 2004 to December 2016. The daily stock dataset contains five attributes: Open price, High price, Low price, Adjust close, and Volume.

<출처: “A Deep Efficient Frontier Method for Optimal Investments,” Sang Il Lee, Seong Joon Yoo, Submitted to and In Revision on Journal of Expert Systems with Applications>

# A Deep Efficient Frontier Method for Optimal Investments

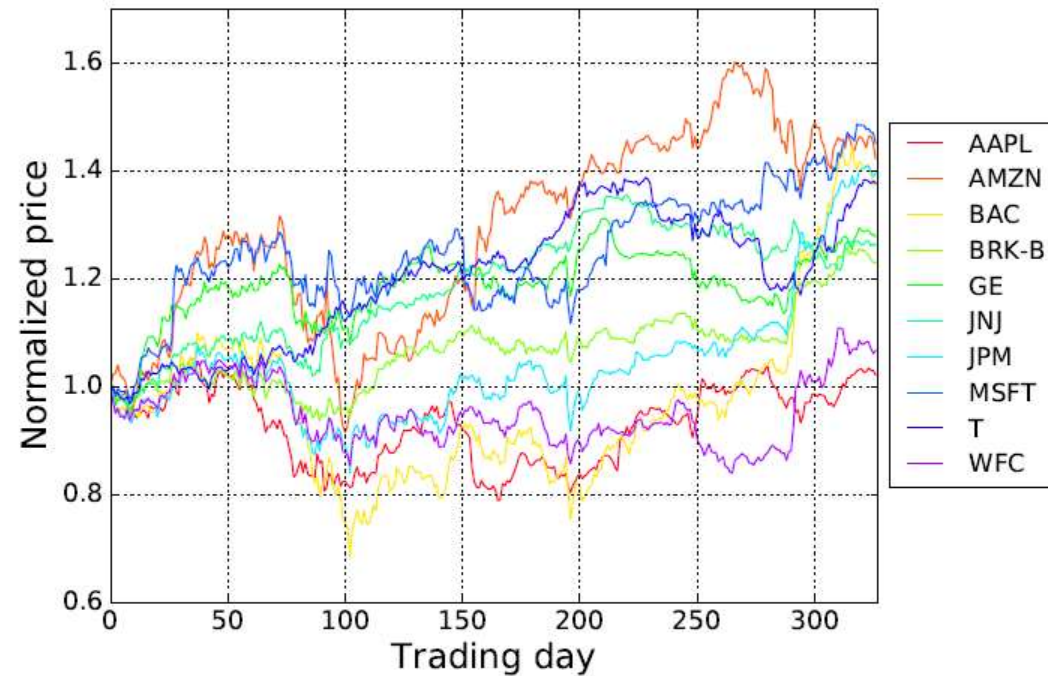


Figure 2: (Color online) Normalized stock prices for the ten sample stocks over the test period

<출처: “A Deep Efficient Frontier Method for Optimal Investments,” Sang Il Lee, Seong Joon Yoo, Submitted to and In Revision on Journal of Expert Systems with Applications>

$$\text{position} = \begin{cases} \text{long} & \text{if } \hat{y}_{t+1} > \theta^+, \\ \text{short} & \text{if } \hat{y}_{t+1} < \theta^-. \end{cases}$$

<출처: “A Deep Efficient Frontier Method for Optimal Investments,” Sang Il Lee, Seong Joon Yoo, Submitted to and In Revision on Journal of Expert Systems with Applications>



# A Deep Efficient Frontier Method for Optimal Investments

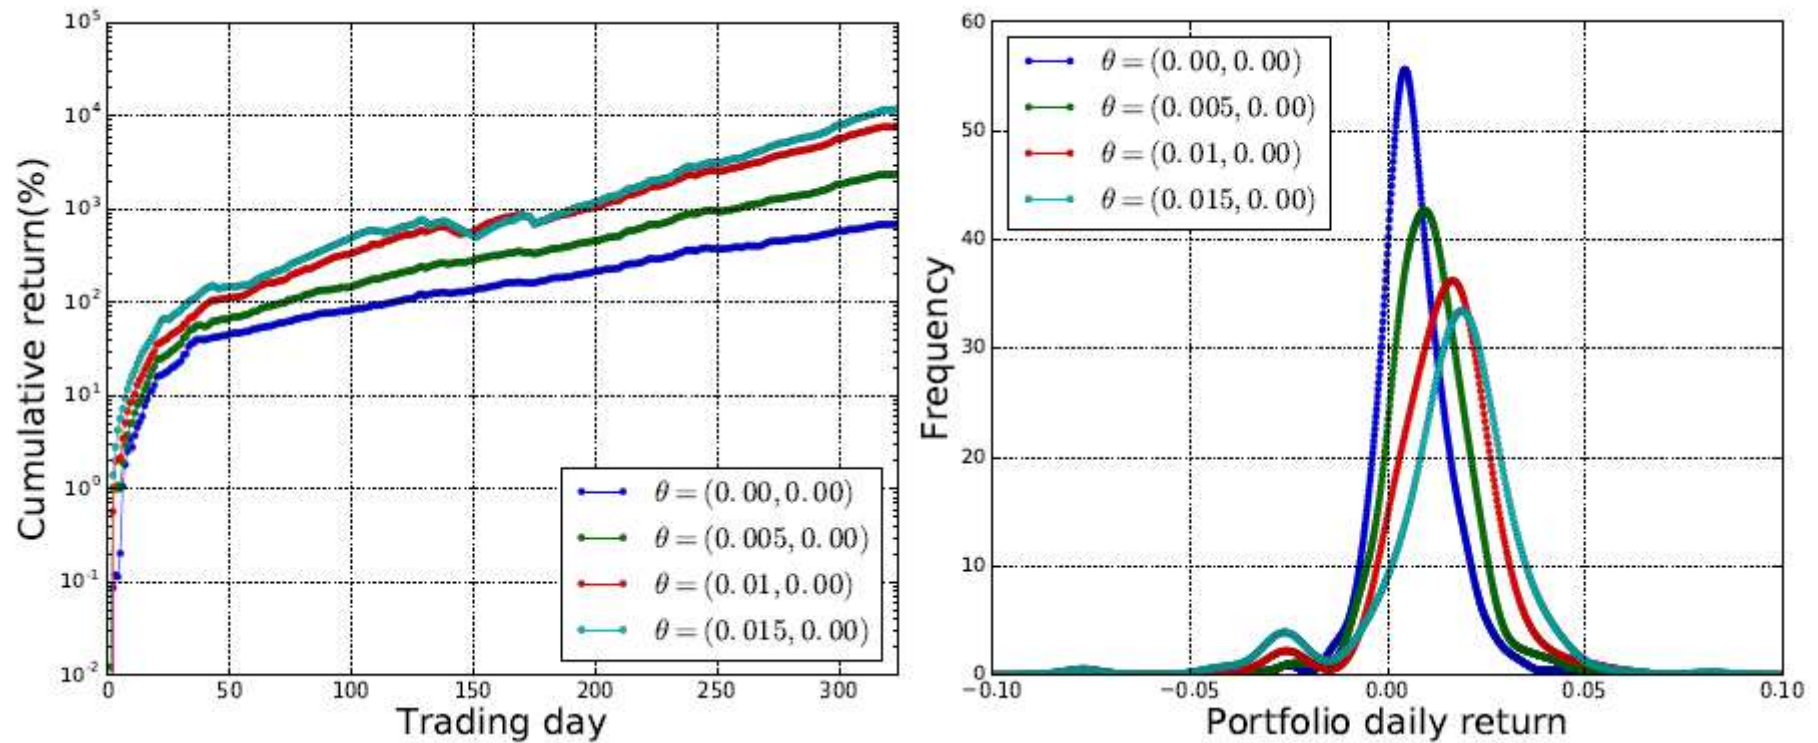
Table 4: Mean and SD for the portfolios consisting of four assets: AAPL, BAC, WFC, JPM.

Portfolio	Statistics	$\theta_1$	$\theta_2$	$\theta_3$	$\theta_4$
Long portfolio	Mean	0.0076	0.0119	0.0143	0.0191
	SD	0.0136	0.0133	0.0169	0.0202
Short portfolio	Mean	0.0073	0.0116	0.0153	0.0223
	SD	0.0113	0.0112	0.0117	0.0112
Long-short portfolio	Mean	0.0086	0.0123	0.0163	0.0197
	SD	0.0096	0.0117	0.0126	0.0151

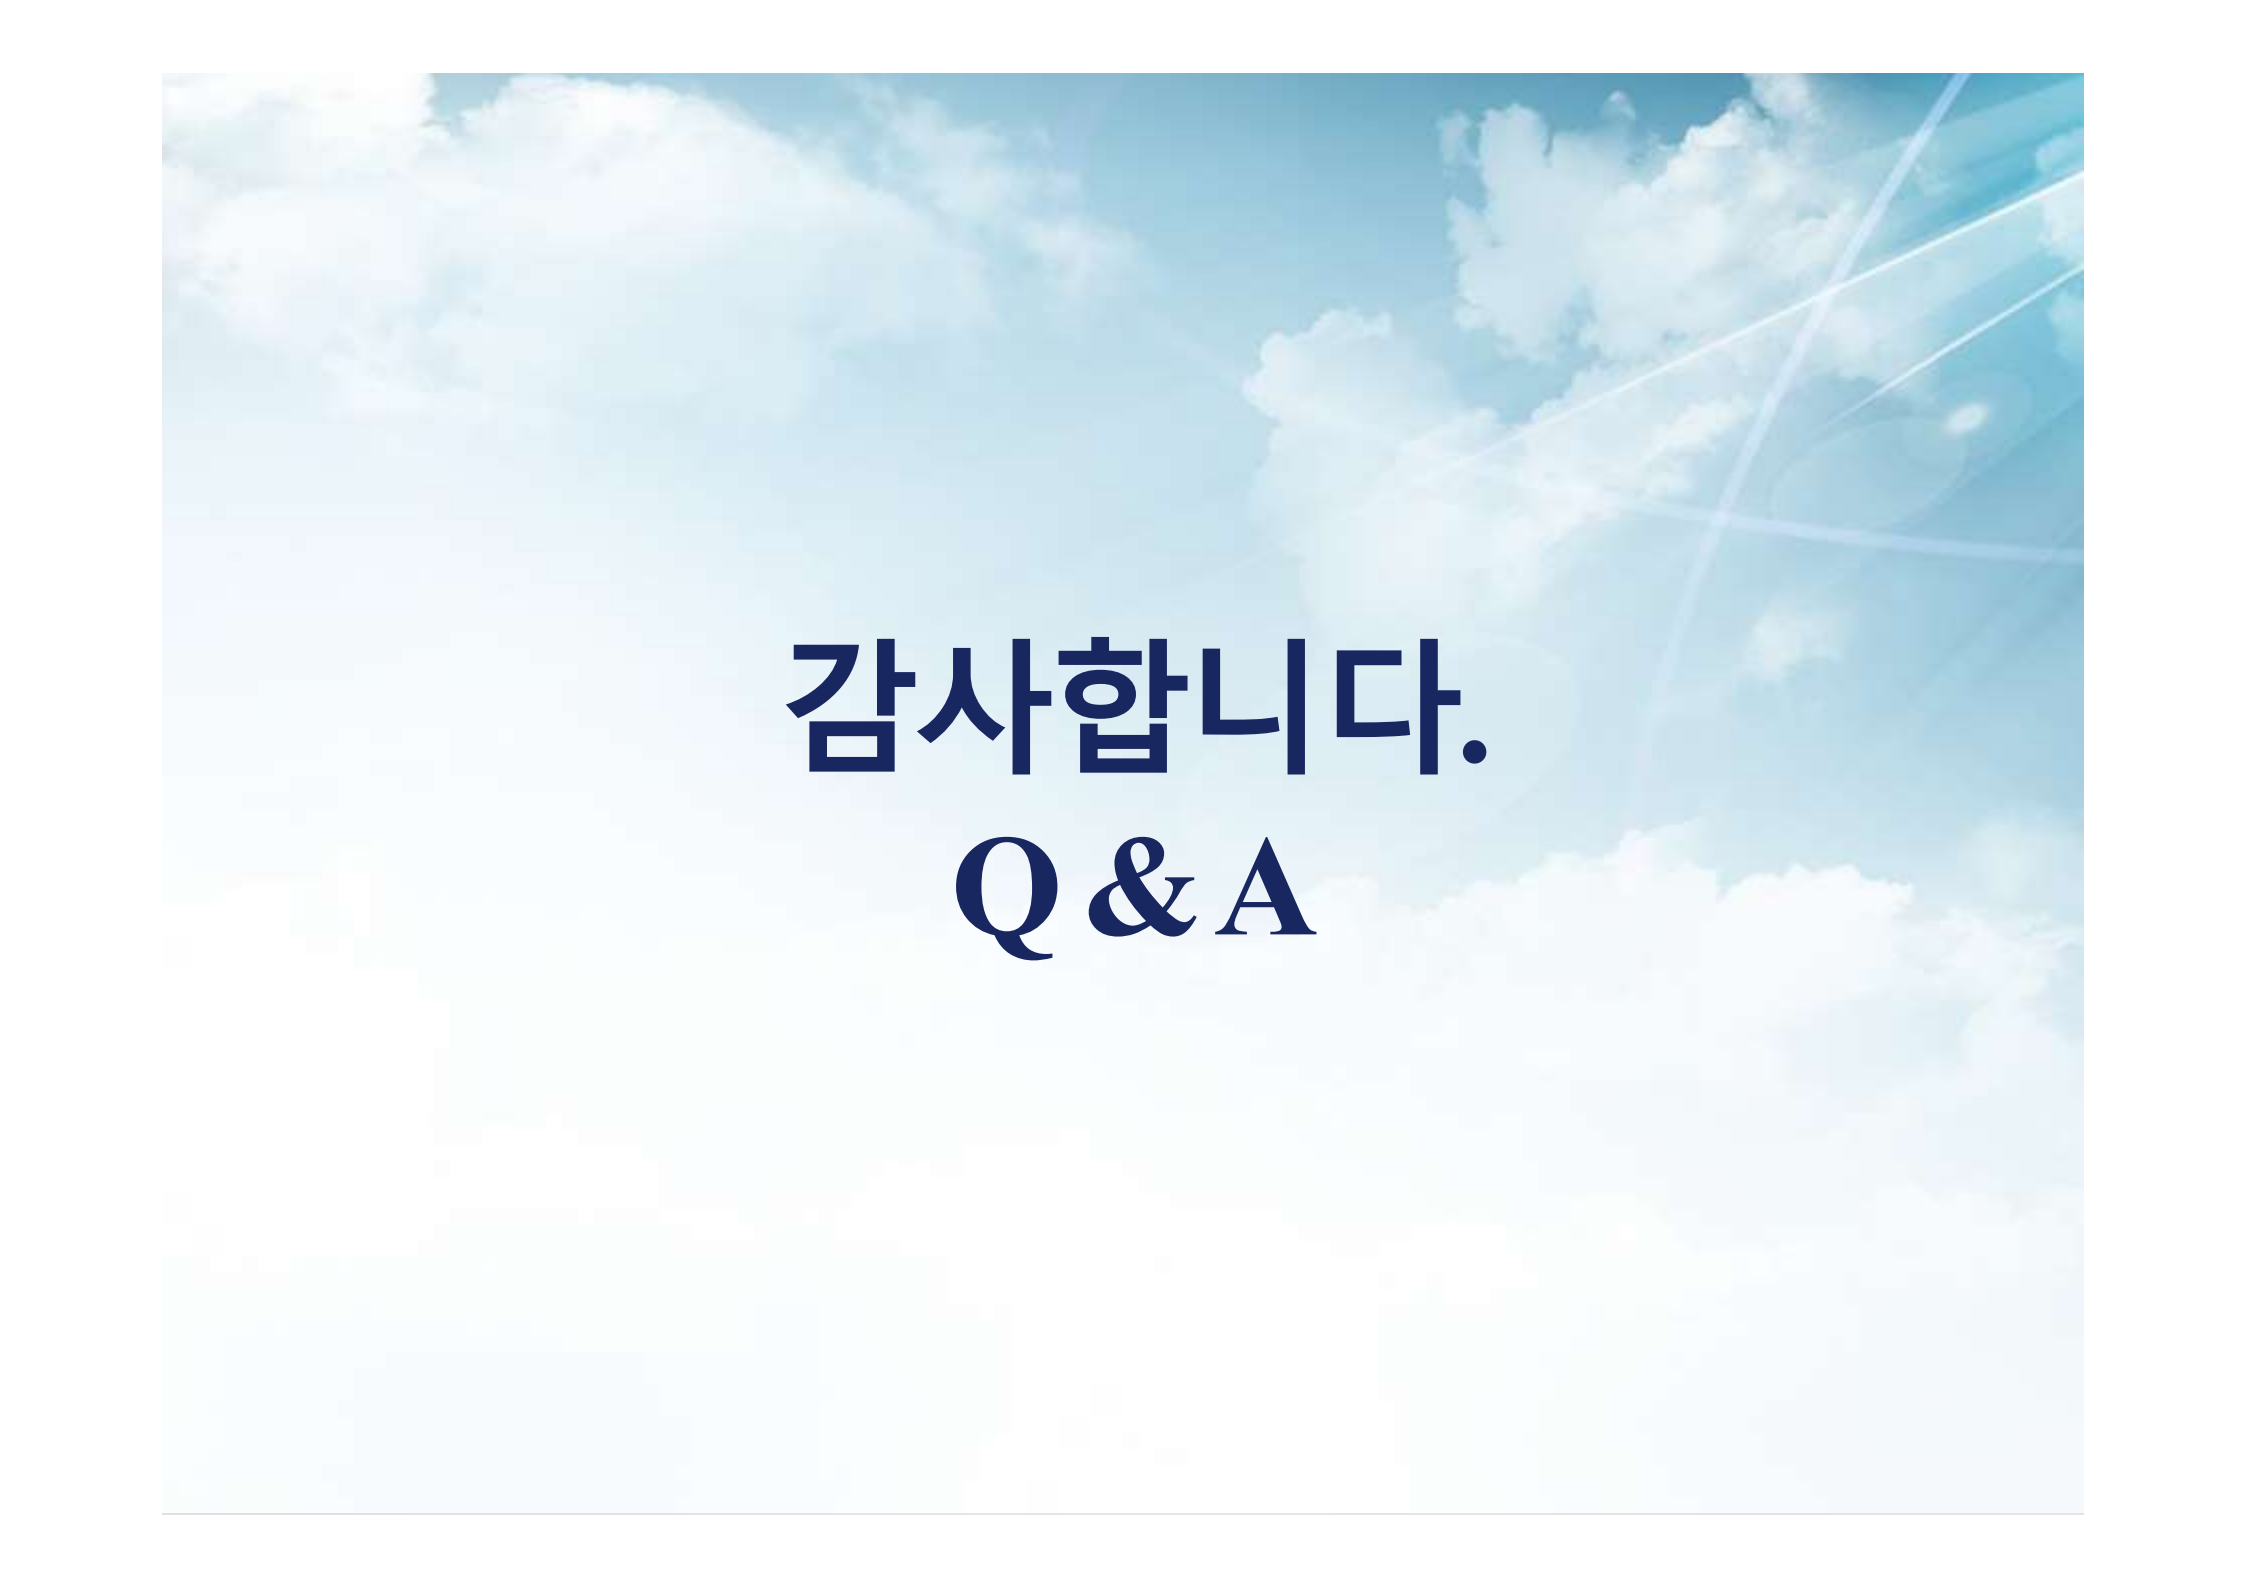
Note: For the long portfolio,  $\theta_1 = (0.00, 0.00)$ ,  $\theta_2 = (0.005, 0.00)$ ,  $\theta_3 = (0.01, 0.00)$ , and  $\theta_4 = (0.015, 0.00)$ . For the short portfolio,  $\theta_1 = (0.00, 0.00)$ ,  $\theta_2 = (0.00, -0.005)$ ,  $\theta_3 = (0.00, -0.01)$ , and  $\theta_4 = (0.00, -0.015)$ . For the long-short portfolio  $\theta_1 = (0.00, 0.00)$ ,  $\theta_2 = (0.005, -0.005)$ ,  $\theta_3 = (0.01, -0.01)$ , and  $\theta_4 = (0.015, -0.015)$ .

<출처: “A Deep Efficient Frontier Method for Optimal Investments,” Sang Il Lee, Seong Joon Yoo, Submitted to and In Revision on Journal of Expert Systems with Applications>

# A Deep Efficient Frontier Method for Optimal Investments



<출처: "A Deep Efficient Frontier Method for Optimal Investments," Sang Il Lee, Seong Joon Yoo, Submitted to and In Revision on Journal of Expert Systems with Applications>



**감사합니다.**  
**Q & A**